

RECOMENDAÇÃO DE MATRÍCULA ACADÊMICA VIA GRAFOS: INTEGRAÇÃO ENTRE ORDENAÇÃO TOPOLÓGICA E O PROBLEMA DO CONJUNTO INDEPENDENTE DE PESO MÁXIMO

2025002205 - Allan Pernes Guimarães

2025003285 - Gabriel Henrique Nogueira Figueira

2025005163 - João Otávio Zampieri Fornazeiro

2025002063 - João Pedro Garcia Torezan

CMAC03 - ALGORITMOS EM GRAFOS

Prof. Rafael Frinhani



INSTITUTO DE
MATEMÁTICA E
COMPUTAÇÃO

UNIFEI - Itajubá



Recomendação de Matrícula Acadêmica via Grafos: Integração entre Ordenação Topológica e o Problema do Conjunto Independente de Peso Máximo

1 Introdução

O planejamento acadêmico adequado é um fator determinante para o sucesso de discentes no ensino superior. A escolha inadequada de disciplinas por semestre — seja por subestimação da carga horária suportável ou por conflitos de horário não percebidos — figura entre as causas mais frequentes de reprovação, trancamento e evasão universitária. No contexto dos cursos de Ciência da Computação (CCO) e Sistemas de Informação (SIN) da Universidade Federal de Itajubá (UNIFEI), essa realidade se manifesta concretamente no histórico acadêmico de discentes que acumulam reprovações em disciplinas para as quais não possuíam a maturidade curricular necessária, ou que se matriculam em conjuntos de matérias com carga horária ou horários incompatíveis com seu ritmo de progressão.

Diante desse cenário, este projeto propõe um sistema computacional de recomendação de matrícula fundamentado em Teoria dos Grafos, capaz de analisar o histórico acadêmico de um discente e recomendar o conjunto de disciplinas que, simultaneamente, maximiza o benefício pedagógico de longo prazo, respeita a capacidade de carga horária individual do aluno e garante a ausência de conflitos de horário entre as matérias selecionadas.

A solução é estruturada em dois níveis de modelagem em grafos. O primeiro é o Grafo Dirigido Acíclico Curricular (G_d), que representa formalmente a estrutura de pré-requisitos da grade curricular. Sobre esse grafo, aplica-se o Algoritmo de Kahn para ordenação topológica, o que permite calcular a profundidade de cada disciplina na cadeia de dependências e, a partir de uma Busca em Largura (BFS) ponderada, estimar o impacto futuro de cada matéria candidata no destrancamento da trajetória acadêmica do aluno. O segundo nível é o Grafo de Conflitos Horários (G_c), um grafo não dirigido cujos vértices são as disciplinas candidatas e cujas arestas representam incompatibilidades de horário entre elas. A seleção final das disciplinas é então formulada como o Problema do Conjunto Independente de Peso Máximo (MWIS) com restrição de capacidade — problema que, na ausência de conflitos, reduz-se exatamente ao clássico Problema da Mochila 0/1.

O desenvolvimento segue a metodologia CRISP-NET [Acuña-Cid et al. \(2025\)](#), que integra as fases do processo de mineração de dados CRISP-DM com o rigor estrutural da Análise de Redes, orientando cada etapa do pipeline — da extração e processamento do histórico acadêmico à geração da recomendação final — de forma sistemática e reproduzível.

1.1 Objetivos do Projeto

O objetivo geral deste projeto é desenvolver um protótipo de software que, a partir do histórico acadêmico de um discente dos cursos de CCO ou SIN da UNIFEI e da oferta de disciplinas do semestre corrente, recomende automaticamente o conjunto de matérias mais adequado para matrícula.

Os objetivos específicos são:

- Modelar a grade curricular dos cursos de CCO e SIN como um Grafo Dirigido Acíclico (G_d), representando formalmente as relações de pré-requisito entre disciplinas;
- Implementar o Algoritmo de Kahn para validação do DAG e atribuição de camadas topológicas, viabilizando o cálculo de profundidade e do Caminho Crítico de cada disciplina;
- Desenvolver um algoritmo de pontuação pedagógica (*score*) que combine destrancamento futuro via BFS, tipo e profundidade da disciplina, afinidade histórica do aluno por área de conhecimento e urgência de oferta semestral;
- Modelar os conflitos de horário entre as disciplinas candidatas como um Grafo de Conflitos (G_c) e resolver o problema de seleção final via MWIS com restrição de carga horária;
- Implementar o pipeline completo em um protótipo funcional em Python, capaz de processar o PDF do histórico acadêmico emitido pelo SIGAA e gerar uma recomendação imediatamente aplicável.

O código-fonte completo do protótipo, os datasets utilizados e a documentação técnica estão disponíveis publicamente no repositório do projeto¹.

2 Trabalhos Relacionados

A literatura científica tem explorado crescentemente o uso de Teoria dos Grafos e Ciência de Redes no domínio da gestão e do planejamento acadêmico. Sistemas de Recomendação Educacional (SRE) aplicados à matrícula de estudantes desempenham um papel crítico tanto no combate à retenção de discentes quanto na otimização do fluxo operacional das instituições de ensino superior.

¹Disponível em: <https://github.com/JoaoPedroGarciaTorezan/Sistema-de-Recomendacao-de-Matriculas>

O referencial metodológico deste trabalho baseia-se em [Acuña-Cid et al. \(2025\)](#), que propuseram o modelo CRISP-NET. Este framework integra as fases tradicionais do processo de mineração de dados industrial (CRISP-DM) com o rigor estrutural da Análise de Redes Sociais e Complexas (SNA). Os autores demonstram que problemas que envolvem dependências complexas ganham maior poder analítico e de otimização quando mapeados topologicamente através de grafos, justificando a divisão do presente ecossistema em estruturas dirigidas e não-dirigidas para guiar o fluxo de tomada de decisão.

No escopo de modelagem curricular estrutural e progressão, [Novais \(2025\)](#) desenvolveu um arcabouço voltado para a geração e análise de grafos curriculares focando no planejamento acadêmico e na análise de métricas estruturais de grades (como centralidade e complexidade estrutural baseada em *Curricular Analytics*). O autor explora como o encadeamento de disciplinas impacta o atraso de formaturas, evidenciando o papel de subgrafos de dependência. Paralelamente, [Kanamori et al. \(2022\)](#) propuseram um sistema de recomendação curricular que analisa o grafo de pré-requisitos sob a ótica do desempenho histórico do estudante para prever o sucesso em disciplinas futuras. Enquanto este estudo foca na previsão probabilística de notas e aquele foca na análise estática de complexidade, o nosso sistema avança em relação a ambos ao transpor essas métricas estruturais para um cálculo dinâmico de *scores* pedagógicos instantâneos, utilizando uma BFS ponderada pelo fator de destrancamento fracional $C(d,x)$ e amplificada pelo Caminho Crítico local como fator multiplicativo.

Sob a perspectiva de personalização de trajetórias, [Queiroz \(2023\)](#) desenvolveu um protótipo de sistema de recomendação voltado especificamente para disciplinas optativas do curso de Sistemas de Informação da UFC Quixadá. O modelo foca na associação de competências e trilhas de carreira profissionais para sugerir matérias com base no interesse vocacional e na abrangência pedagógica das ementas. Embora o trabalho traga contribuições relevantes ao engajamento estudantil através da afinidade, ele negligencia as barreiras físicas operacionais do processo de inscrição, tais como a limitação de carga horária e o choque de horários de turmas no mundo real.

Essa limitação operacional de horários de aulas (*timetabling*) é discutida por [Al-Yahya et al. \(2023\)](#), que abordam sistemas de recomendação baseados em algoritmos de otimização combinatória para garantir que as listas de sugestões feitas aos discentes não gerem conflitos temporais de agendamento. Todavia, abordagens focadas puramente em otimização de horários tendem a tratar o problema de forma linear ou isolada das dependências pedagógicas críticas de longo prazo do aluno.

O diferencial competitivo e a principal contribuição deste projeto residem na unificação convergente dessas frentes. Adota-se a visão pedagógica estrutural de [Novais \(2025\)](#) e [Kanamori et al. \(2022\)](#) (via DAG Curricular G_d e algoritmo de Kahn), associada ao direcionamento de afinidade por área inspirado por [Queiroz \(2023\)](#). Contudo, expande-se o escopo ao acoplar essas variáveis latentes às restrições físicas operacionais tratadas por [Al-Yahya et al. \(2023\)](#) por meio de um segundo nível de modelagem: o Grafo de Conflitos Horários (G_c), formalmente resolvido sob a ótica do Problema do Conjunto Independente de Peso Máximo (MWIS) restrito à capacidade de mochila. Dessa forma, assegura-se que a recomendação ge-

rada seja pedagogicamente ideal e, simultaneamente, livre de choques físicos e imediatamente aplicável no SIGAA.

3 Metodologia

O desenvolvimento deste trabalho foi orientado pela metodologia CRISP-NET [Acuña-Cid et al. \(2025\)](#), que integra as fases do processo de mineração de dados CRISP-DM com o rigor estrutural da Análise de Redes. Sob essa perspectiva, o pipeline foi estruturado em seis etapas sequenciais — da aquisição e modelagem dos dados à geração da recomendação final —, cada uma responsável por uma transformação bem definida sobre as estruturas de grafos do sistema.

3.1 Detalhamento do Problema

O problema central abordado neste projeto consiste em, dado o histórico acadêmico de um discente dos cursos de Ciência da Computação (CCO) ou Sistemas de Informação (SIN) da UNIFEI e a oferta de disciplinas de um semestre específico, determinar o conjunto de matérias que simultaneamente: (i) respeita os pré-requisitos definidos pela grade curricular; (ii) maximiza o benefício pedagógico de longo prazo do aluno, considerando o destrancamento de disciplinas futuras e a afinidade histórica do discente por área de conhecimento; e (iii) garante a ausência de conflitos de horário entre as matérias selecionadas, respeitando ainda a capacidade individual de carga horária do estudante.

A escolha inadequada de disciplinas — por sobrecarga de carga horária ou por conflitos de horário não percebidos — figura entre as causas frequentes de reprovação e retenção no ensino superior. O sistema proposto busca mitigar esses fatores ao tornar explícitas, por meio de estruturas de grafos, as dependências curriculares e as incompatibilidades operacionais que costumam permanecer opacas ao estudante no momento da matrícula.

Formalmente, o problema é decomposto em dois níveis de modelagem em grafos: um **Grafo Dirigido Acíclico Curricular** (G_d), que representa as dependências pedagógicas entre disciplinas, e um **Grafo de Conflitos Horários** (G_c), que representa as incompatibilidades temporais entre as candidatas à matrícula. A seleção final é formulada como o Problema do Conjunto Independente de Peso Máximo (do inglês *Maximum Weight Independent Set*, MWIS) com restrição de capacidade, conforme detalhado nas subseções seguintes.

3.2 Modelagem

3.2.1 Datasets

O sistema opera sobre duas fontes de dados principais, ambas construídas pelo grupo:

- **Matrizes curriculares** (`curriculo_CCO_HORARIOS.csv` e `curriculo_SIN_HORARIOS.csv`): arquivos CSV construídos manualmente a partir das grades curriculares oficiais dos cursos de CCO e SIN da UNIFEI. Cada linha representa uma disciplina e contém os atributos descritos na Tabela 1.

- **Histórico acadêmico do aluno:** fornecido pelo próprio discente na forma do PDF emitido pelo SIGAA. O arquivo é processado em tempo de execução pelo módulo `parse_historico.py`, que extrai a tabela de componentes curriculares cursados e gera um *DataFrame* em memória com os campos descritos na Tabela 2.

3.2.2 Grafo Dirigido Acíclico Curricular (G_d)

A grade curricular é modelada como um Grafo Dirigido Acíclico $G_d = (V, E)$, onde:

- V é o conjunto de disciplinas do currículo, cada uma representada por um vértice com atributos {codigo, nome, tipo, area, periodo, oferta, ch, prereqs, equivalentes};
- E é o conjunto de arestas dirigidas, onde a aresta $A \rightarrow B$ indica que A é pré-requisito direto de B .

Sobre G_d executa-se o **Algoritmo de Kahn Kahn (1962)**, que realiza a ordenação topológica do grafo e atribui a cada vértice uma *camada topológica (layer)*, definida como:

$$\text{layer}(v) = \max_{u \in \text{predecessores}(v)} (\text{layer}(u)) + 1 \quad (1)$$

com $\text{layer}(v) = 0$ para vértices raiz (sem pré-requisitos). O algoritmo de Kahn também cumpre o papel de **validação estrutural**: caso o grafo contenha ciclos — situação indesejável mas possível em grades com co-requisitos — os vértices participantes do ciclo são detectados e as arestas responsáveis pelo fechamento do ciclo são removidas, com aviso ao operador. A camada topológica de cada vértice é utilizada posteriormente no cálculo do *score* pedagógico.

A Figura 1 ilustra a estrutura completa de G_d para o currículo de CCO, evidenciando a organização em camadas topológicas (períodos 1 a 8) obtida pelo Algoritmo de Kahn, bem como a aplicação prática do pipeline sobre um histórico real.

3.2.3 Grafo de Conflitos Horários (G_c)

O segundo nível de modelagem representa as incompatibilidades temporais entre disciplinas. Dado o conjunto C de disciplinas candidatas à matrícula (saída da etapa de filtragem), define-se o grafo não dirigido $G_c = (C, E_c)$, onde:

$$E_c = \{(A, B) \mid A, B \in C, A \neq B, \text{slots}(A) \cap \text{slots}(B) \neq \emptyset\} \quad (2)$$

sendo $\text{slots}(d)$ o conjunto de slots de horário da disciplina d , cada slot identificado pelo par (dia da semana, horário de início). A detecção de conflito é realizada por interseção de conjuntos após normalização textual dos slots, que remove acentuação e padroniza o formato para `dia_HH:MM`, tornando a comparação robusta a variações de escrita no CSV.

3.3 Desenvolvimento

3.3.1 Estratégia de Solução

O pipeline completo é composto por seis módulos sequenciais, orquestrados pelo `main.py` conforme o fluxo da Figura ?? . As subseções a seguir detalham cada módulo.




Figura 1: Visualização do Grafo Dirigido Acíclico curricular (G_d) do curso de Ciência da Computação, organizado por camada topológica (período). Os vértices são coloridos conforme a situação do discente no histórico (concluída, reprovada, disponível ou não cursada); o contorno em destaque indica as disciplinas selecionadas pelo MWIS para o semestre 2025.1.

3.3.2 Módulo 1 — Extração do Histórico Acadêmico (`parse_historico.py`)

O histórico acadêmico do aluno é fornecido como PDF emitido pelo SIGAA. Como o documento não possui uma API estruturada de acesso, adotou-se extração textual via `pdf2text` -layout, que preserva o alinhamento de colunas da tabela de componentes curriculares. Sobre o texto extraído, aplica-se uma expressão regular posicional que identifica cada linha de disciplina pelos seus campos em colunas fixas:

```
(semestre) (flag) (codigo) (h_aula) (CH)
(turma) (freq) (nota_min) (media) (situacao)
```

A *flag* opcional codifica o tipo da disciplina (* para optativa, e para equivalente de obrigatória, # para eletiva). O nome da disciplina, não presente na mesma linha dos dados numéricos, é recuperado por retrospectiva nas até oito linhas anteriores, filtrando falsos positivos via uma segunda expressão regular. O módulo retorna diretamente um *DataFrame* Pandas em memória, sem persistência em disco.

Tabela 1: Atributos das matrizes curriculares (curriculo_CCO/SIN_HORARIOS.csv).

Coluna	Tipo	Descrição
CODIGO	string	Identificador único da disciplina (ex.: CRSC03)
NOME	string	Nome completo da disciplina
TIPO	string	OBRIGATORIA, OPTATIVA ou TCC
AREA	string	Área temática do currículo
PERIODO	int	Período sugerido; valores múltiplos (ex.: 5 7) usam o menor
OFERTA	string	1º SEMESTRE, 2º SEMESTRE ou ANUAL
CH	int	Carga horária em horas
PREREQUISITOS	string	Códigos separados por
EQUIVALENTES	string	Códigos de disciplinas equivalentes, separados por
HORARIOS	string	Slots de aula no formato Dia HH:MM, separados por

Tabela 2: Atributos do histórico acadêmico extraído do PDF do SIGAA.

Coluna	Descrição
semestre	Período letivo (ex.: 2023. 1) ou TRANSFERENCIA
codigo	Código da disciplina
nome	Nome da disciplina
tipo_flag	OPTATIVA, EQUIVALENTE_OBRIG, ELETIVA, etc.
ch	Carga horária
frequencia	Frequência percentual
nota_min	Nota mínima
media	Média final obtida
situacao	APR, REP, MATR, CUMP, TRANC, etc.

3.3.3 Módulo 2 — Construção do DAG e Ordenação Topológica (dag_cco.py)

A partir do CSV do currículo selecionado (CCO ou SIN), constroem-se os vértices de G_d e suas arestas de pré-requisito. O **Algoritmo de Kahn** é executado em duas passagens: uma provisória para identificar ciclos e uma definitiva para atribuir camadas. O pseudocódigo do Kahn implementado é apresentado no Algoritmo 1.

Algorithm 1: Algoritmo de Kahn para ordenação topológica

Input: Grafo direcionado acíclico $G = (V, E)$

Output: Ordem topológica T

```

1 Inicializar grau_entrada[v] para todo  $v \in V$ ;
2 Inicializar fila  $Q$  com todos os vértices de grau de
  entrada igual a zero;
3  $T \leftarrow []$ ;
4 while  $Q \neq \emptyset$  do
5    $u \leftarrow Q.\text{remover}()$ ;
6   Inserir  $u$  no final de  $T$ ;
7   for cada  $v \in \text{sucessores}(u)$  do
8     grau_entrada[v]  $\leftarrow$  grau_entrada[v] - 1;
9     if grau_entrada[v] = 0 then
10       Inserir  $v$  em  $Q$ ;
11     end
12   end
13 end
14 return  $T$ ;
```

Se $|T| < |V|$, existem vértices não alcançados, indicando ciclo residual. Vértices em ciclo são reportados como aviso; suas arestas de fechamento de ciclo são removidas antes da

passagem definitiva, com base no critério de período sugerido (a aresta que aponta do período maior para o menor é descartada).

3.3.4 Módulo 3 — Processamento do Histórico (read_historico.py)

O histórico do aluno é processado para extrair três estruturas utilizadas pelas etapas seguintes:

1. **Conjunto de aprovadas $\mathcal{A}$:** disciplinas com situação APR, APRN, CUMP ou DISP, expandidas pelas equivalências definidas no currículo (se $d_1 \in \mathcal{A}$ e d_1 é equivalente de d_2 , então d_2 é considerada satisfeita);
2. **Capacidade de carga horária W :** estimada pela média de carga horária aprovada por semestre real (excluindo semestres de transferência e cancelamentos), arredondada para o múltiplo de 16 horas mais próximo:

$$W = 16 \cdot \left\lceil \frac{\overline{\text{CH}}_{\text{semestre}}}{16} + 0.5 \right\rceil \quad (3)$$

3. **Afinidade por área $\alpha(a)$:** média das notas de disciplinas aprovadas pertencentes à área a , normalizada para a escala $[0, 1]$:

$$\alpha(a) = \frac{\overline{\text{nota}}_{\text{APR}, a}}{10} \quad (4)$$

Áreas sem histórico de aprovação recebem $\alpha(a) = 0,5$ (valor neutro).

3.3.5 Módulo 4 — Filtragem de Candidatas (filtro_disciplinas.py)

Uma disciplina $d \in V$ é considerada **candidata à matrícula** no semestre s se e somente se satisfaz simultaneamente três critérios:

1. **Oferta ativa em s :** disciplinas com oferta 1º SEMESTRE são candidatas apenas em semestres .1; 2º SEMESTRE apenas em .2; ANUAL em qualquer semestre.
2. **Não aprovada:** $d \notin \mathcal{A}$ e nenhum equivalente de d pertence a $\mathcal{A}$.
3. **Pré-requisitos satisfeitos:** para todo $p \in \text{prereqs}(d)$, tem-se $p \in \mathcal{A}$ ou algum equivalente de p pertence a $\mathcal{A}$.

O resultado é a lista C de candidatas, ordenada por período sugerido e código.

3.3.6 Módulo 5 — Cálculo do Score Pedagógico (score.py)

Para cada candidata $d \in C$, calcula-se um *score* que combina quatro fatores:

$$\begin{aligned} \text{score}(d) = & (\text{score_bfs}(d) + \text{score_base}(d)) \\ & \times \alpha(\text{area}(d)) \\ & \times F_{\text{oferta}}(d) \\ & \times (1 + F_{\text{critico}}(d)) \end{aligned} \quad (5)$$

Score BFS — captura o impacto pedagógico de longo prazo de d sobre as disciplinas que ela desbloqueia. Uma BFS a partir de d em G_d identifica o conjunto de descendentes $\mathcal{D}(d)$; para cada descendente x , calcula-se a contribuição parcial:

$$\text{score_bfs}(d) = \sum_{x \in \mathcal{D}(d)} C(d, x) \cdot P(x) \cdot F(x) \quad (6)$$

c onde:

$$C(d, x) = \min\left(\frac{|\text{prereqs}(x) \cap \mathcal{A}| + 1}{|\text{prereqs}(x)|}, 1\right) \quad (7)$$

$$P(x) = \begin{cases} 2,0 & \text{se } x \text{ é TCC} \\ 1,0 & \text{se } x \text{ é OBRIGATORIA} \\ 0,5 & \text{se } x \text{ é OPTATIVA} \end{cases} \quad (8)$$

$$F(x) = \frac{1}{\text{layer}(x) + 1} \quad (9)$$

O fator $C(d, x)$ representa a contribuição fracional de d para o destrancamento de x : o +1 no numerador contabiliza a futura aprovação em d ainda não realizada. $P(x)$ pondera pelo impacto curricular do descendente; $F(x)$ penaliza descendentes mais distantes na cadeia topológica, priorizando benefícios mais imediatos.

Score Base — valor intrínseco de d , independente de seus descendentes:

$$\text{score_base}(d) = P(d) \cdot F(d) \quad (10)$$

Garante que disciplinas folha (sem descendentes em G_d) recebam pontuação proporcional ao seu tipo e profundidade,

evitando que $\text{score_bfs}(d) = 0$ nivele indevidamente obrigatórias e optativas terminais.

Fator de urgência de oferta:

$$F_{\text{oferta}}(d) = \begin{cases} 2,0 & \text{se } d \text{ é SEMESTRAL} \\ 1,0 & \text{se } d \text{ é ANUAL} \end{cases} \quad (11)$$

Disciplinas semestrais recebem peso maior, pois perder o semestre implica aguardar um ano inteiro para cursá-las novamente.

Fator de caminho crítico — amplifica o score de disciplinas que encabeçam as cadeias de pré-requisitos mais longas do currículo. O caminho crítico de d é calculado por programação dinâmica sobre o subgrafo de G_d alcançável a partir de d , ordenado pela camada topológica:

$$F_{\text{critico}}(d) = \frac{\text{caminho_critico}(d)}{\max_{d' \in C} \text{caminho_critico}(d')} \quad (12)$$

O valor é normalizado em $[0, 1]$, sendo $F_{\text{critico}} = 1$ para a disciplina com a maior cadeia de dependências futuras. O fator entra na Equação (5) como $(1 + F_{\text{critico}})$, de forma a ampliar — e não apenas adicionar — o impacto das demais componentes. O Algoritmo 2 resume o cálculo completo do score para o conjunto de candidatas.

Algorithm 2: Cálculo do score de recomendação das disciplinas candidatas

Input: G_d (DAG curricular); C (disciplinas candidatas); Aluno (histórico e afinidades); ℓ (camadas topológicas via Kahn)

Output: Scores — dicionário código $\rightarrow$ score final

```

1 Max_Caminho_Global  $\leftarrow$  0;
2 Caminhos_Criticos  $\leftarrow$   $\emptyset$ ;
3 // Passo 1 - caminho crítico local e máximo global
4 for cada  $d \in C$  do
5   Caminhos_Criticos[ $d$ ]  $\leftarrow$  CalcularCaminhoCriticoBFS( $G_d, d$ );
6   if Caminhos_Criticos[ $d$ ] > Max_Caminho_Global then
7     Max_Caminho_Global  $\leftarrow$  Caminhos_Criticos[ $d$ ];
8   end
9 end
10 Scores  $\leftarrow$   $\emptyset$ ;
11 // Passo 2 - score ponderado por disciplina
12 for cada  $d \in C$  do
13    $F_d \leftarrow 1/\ell(d)$ ; // fator de profundidade
14    $P_d \leftarrow$  ObterPesoTipo( $d$ ); // 2,0 TCC | 1,0 OBRIG | 0,5 OPT
15   Score_Base  $\leftarrow$   $P_d \times F_d$ ;
16   Score_BFS  $\leftarrow$  0;
17   Descendentes  $\leftarrow$  ObterDescendentesBFS( $G_d, d$ );
18   for cada  $x \in$  Descendentes do
19      $F_x \leftarrow 1/\ell(x)$ ;
20      $P_x \leftarrow$  ObterPesoTipo( $x$ );
21      $C_{d,x} \leftarrow \frac{\text{PreReqsSatisfeitos}(x, \text{Aluno}) + 1}{\text{TotalPreReqs}(x)}$ ;
22     Score_BFS  $\leftarrow$  Score_BFS + ( $C_{d,x} \times P_x \times F_x$ );
23   end
24   Afinidade  $\leftarrow$  Aluno.AfinidadeArea[Area( $d$ )];
25    $F_{\text{oferta}} \leftarrow$  ObterFatorOferta( $d$ ); // 2,0 SEMESTRAL | 1,0 ANUAL
26    $F_{\text{critico}} \leftarrow$  0;
27   if Max_Caminho_Global > 0 then
28      $F_{\text{critico}} \leftarrow$  Caminhos_Criticos[ $d$ ] / Max_Caminho_Global;
29   end
30   Scores[ $d$ ]  $\leftarrow$  (Score_BFS + Score_Base)  $\times$  Afinidade  $\times$   $F_{\text{oferta}} \times (1 + F_{\text{critico}})$ ;
31 end
32 return Scores;
```

3.3.7 Módulo 6 — Grafo de Conflitos e Seleção Final por MWIS (mwis.py)

Com os scores calculados, a seleção final das disciplinas é formulada como o **Problema do Conjunto Independente de Peso Máximo** (MWIS) com restrição de capacidade:

$$\begin{aligned} & \text{Maximizar} && \sum_{d \in C} \text{score}(d) \cdot x_d \\ & \text{Sujeito a} && \sum_{d \in C} \text{CH}(d) \cdot x_d \leq W \\ & && x_a + x_b \leq 1, \quad \forall (a, b) \in E_c \\ & && x_d \in \{0, 1\}, \quad \forall d \in C \end{aligned} \quad (13)$$

onde $x_d = 1$ indica que d é selecionada para a recomendação. A restrição $x_a + x_b \leq 1$ garante que nenhum par de disciplinas com conflito de horário seja simultaneamente recomendado. Note-se que, na ausência de conflitos ($E_c = \emptyset$), a formulação reduz-se exatamente ao Problema da Mochila 0/1 clássico.

A estratégia de solução é adaptativa em função do tamanho do conjunto de candidatas, conforme descrito no Algoritmo 3:

- **Enumeração exata** ($|C| \leq 20$): todos os subconjuntos de C são enumerados (no máximo $2^{20} \approx 1,05 \times 10^6$ iterações), verificando para cada um a independência em G_c e o respeito à capacidade W . Seleciona-se o subconjunto de maior score total. Na prática, $|C|$ raramente excede 15 disciplinas por semestre, mantendo a estratégia exata como regra. O procedimento é detalhado no Algoritmo 4.
- **Heurística gulosa** ($|C| > 20$): as candidatas são ordenadas por eficiência $\text{score}(d)/\text{CH}(d)$ em ordem decrescente. Itera-se sobre a lista, selecionando cada disciplina que não conflite com as já escolhidas e que caiba na capacidade restante. Os vizinhos no grafo G_c da disciplina selecionada são bloqueados para as iterações seguintes, conforme o Algoritmo 5.

Algorithm 3: Resolução de matrícula via grafo de conflitos (MWIS restrito)

Input: C (candidatas); Scores; W (capacidade de CH); Horarios (slots por disciplina)
Output: Solução — subconjunto ótimo/heurístico para matrícula

```

1  $V_c \leftarrow C$ ;
2  $E_c \leftarrow \emptyset$ ;
3 // Passo 1 - construção do grafo de conflitos
   $G_c = (V_c, E_c)$ 
4 for cada par  $(u, v) \in \binom{V_c}{2}$  do
5   if CompartilhamSlot(Horarios[ $u$ ], Horarios[ $v$ ]) then
6      $E_c \leftarrow E_c \cup \{(u, v)\}$ ;
7   end
8 end
9 // Passo 2 - estratégia híbrida
10 if  $|V_c| \leq 20$  then
11   Solução  $\leftarrow$  ResolverExato( $V_c, E_c$ , Scores,  $W$ );
12 end
13 else
14   Solução  $\leftarrow$  ResolverGuloso( $V_c, E_c$ , Scores,  $W$ );
15 end
16 return Solução;
```

Algorithm 4: ResolverExato — enumeração exaustiva de subconjuntos ($|V_c| \leq 20$)

Input: V_c, E_c , Scores, W
Output: Melhor subconjunto independente sob a restrição de capacidade

```

1 Melhor_Score  $\leftarrow$  0;
2 Melhor_Subconjunto  $\leftarrow \emptyset$ ;
3 for  $k \leftarrow 1$  até  $|V_c|$  do
4   for cada  $S \in \binom{V_c}{k}$  do
5     if CargaHorariaTotal( $S$ )  $\leq W$  e  $S$  é independente em  $E_c$  then
6        $\text{score}_S \leftarrow \sum_{d \in S} \text{Scores}[d]$ ;
7       if  $\text{score}_S > \text{Melhor\_Score}$  then
8         Melhor_Score  $\leftarrow \text{score}_S$ ;
9         Melhor_Subconjunto  $\leftarrow S$ ;
10      end
11    end
12  end
13 end
14 return Melhor_Subconjunto;
```

Algorithm 5: ResolverGuloso — heurística por densidade de score ($|V_c| > 20$)

Input: $V_c, E_c, \text{Scores}, W$

Output: Subconjunto independente viável (aproximado)

```

1 Seleccionadas  $\leftarrow \emptyset$ ;
2 CH_Atual  $\leftarrow 0$ ;
3 Ordenar  $V_c$  decrescentemente por  $\text{Scores}[d] / \text{CH}(d)$ ;
4 for cada  $d \in V_c$  (ordem decrescente) do
5   if  $\text{CH\_Atual} + \text{CH}(d) \leq W$  e  $d$  não conflita com
     Seleccionadas em  $E_c$  then
6     Seleccionadas  $\leftarrow \text{Seleccionadas} \cup \{d\}$ ;
7     CH_Atual  $\leftarrow \text{CH\_Atual} + \text{CH}(d)$ ;
8   end
9 end
10 return Seleccionadas;

```

3.3.8 Saída (main.py)

O módulo `main.py` implementa uma interface de linha de comando (CLI) que guia o usuário pelos três inputs necessários — curso (CCO ou SIN), caminho do PDF do histórico e semestre atual —, valida cada entrada e executa o pipeline completo com tratamento de erros em cada etapa. Ao final, gera o arquivo `recomendacao_{CURSO}_{SEMESTRE}.txt` com a lista de disciplinas recomendadas, o detalhamento do score de cada uma, os horários, a carga horária total utilizada e as métricas da execução do MWIS.

A título de ilustração, a Tabela 3 apresenta o resultado gerado pelo sistema para um aluno do curso de CCO no semestre 2025.1. O sistema identificou 18 arestas no grafo de conflitos G_c e selecionou, via enumeração exata, o par de disciplinas que maximiza o score total respeitando a capacidade de 144 horas e a ausência de sobreposição de horários. Os vértices destacados na Figura 1 correspondem exatamente às disciplinas selecionadas nesta tabela.

4 Resultados e Discussão

O protótipo foi validado com históricos acadêmicos reais de sete discentes — cinco do curso de Ciência da Computação (identificados como CCO-1², CCO-2, CCO-3, CCO-4 e CCO-5) e dois do curso de Sistemas de Informação (SIN-1 e SIN-2) —, todos avaliados para o semestre 2026.2, com exceção de CCO-1, avaliado para 2025.1. Os perfis selecionados cobrem situações distintas de progressão curricular, o que permitiu observar o comportamento do sistema sob diferentes condições de capacidade, afinidade e densidade de conflitos de horário. A Tabela 4 resume as execuções.

4.1 Saturação da capacidade de carga horária

Em seis dos sete casos testados, a solução selecionada utilizou **100% da capacidade de carga horária** calculada para o aluno, contra 88,9% no caso de CCO-1. Esse resultado é uma evidência indireta de que a formulação do MWIS com restrição de mochila (Equação 13) está operando corretamente: o algoritmo busca exaurir o orçamento de horas disponível sempre que existem candidatas suficientes e compatíveis em horário

para fazê-lo, em vez de parar prematuramente com folga de capacidade.

O caso de CCO-1 ilustra a situação oposta — apenas duas disciplinas (CRSC03 e MAT00A, ambas selecionadas, conforme destacado na Figura 1) foram recomendadas, deixando 16h de capacidade ociosa. Isso decorre da combinação de dois fatores: a baixa quantidade de candidatas disponíveis no primeiro período do curso (poucas disciplinas sem pré-requisito) e a presença de conflitos de horário entre elas, que impede a inclusão de uma terceira disciplina de carga horária compatível sem violar a independência exigida pela Equação 13. É interessante notar que CCO-5, com perfil de candidatas igualmente reduzido (apenas duas disciplinas recomendadas), conseguiu saturar integralmente sua capacidade de 128h — diferença explicada pela ausência, nesse caso específico, de uma terceira candidata viável em horário compatível, mas com carga horária que somasse exatamente ao limite restante.

4.2 Efeito da afinidade por área

A afinidade $\alpha(a)$ funcionou como o fator de maior impacto multiplicativo observado nos resultados. No caso CCO-4, a disciplina ADM58H (Psicologia Organizacional e do Trabalho) recebeu $\text{score_bfs} = 0$ — por não possuir descendentes desbloqueáveis na grade — mas ainda assim foi selecionada, sustentada inteiramente pelo score_base e por uma afinidade de 0,637 na área de Aspectos Humanos em Computação. Padrão semelhante ocorre em SIN-1 com IEPG15 e ADM54H, e em SIN-2 com XAHC01, IEPG14 e IEPG15, todas com $\text{score_bfs} = 0$ e caminho crítico nulo, mas selecionadas por carregarem afinidade entre 0,62 e 0,81. Em CCO-2, ADM54H repete o mesmo padrão, com afinidade de 0,665 compensando a ausência total de descendentes desbloqueáveis.

Esse comportamento confirma experimentalmente a função do score_base (Equação 10), introduzido precisamente para evitar que disciplinas terminais da grade — frequentemente optativas de caráter humanístico ou de gestão, mas também obrigatórias terminais como XAHC01 e IEPG14 em SIN-2 — fossem descartadas por score zero diante de obrigatórias com encadeamento mais profundo. Sem esse termo, seis das vinte e cinco recomendações analisadas nesta seção teriam pontuação base nula e dependeriam apenas dos multiplicadores para competir com as demais candidatas.

Por outro lado, observa-se em CCO-3, CCO-4 e CCO-5 que disciplinas de áreas sem histórico prévio do aluno recebem o valor neutro $\alpha = 0,5$ — caso de CTC001 (Teoria da Computação) em CCO-3, de IEPG01 (Administração e Gestão) em CCO-4, e de CTC001 novamente em CCO-5 — o que as posiciona de forma intermediária frente a disciplinas com afinidade comprovadamente alta ou baixa, sem penalizá-las nem favorecê-las indevidamente.

4.3 Caminho crítico e priorização de disciplinas-gargalo

O fator F_{critico} (Equação 12) cumpriu o papel de identificar disciplinas que funcionam como gargalo estrutural da grade. Em CCO-3, CTC001 (Algoritmos e Estruturas de Dados I) e CRSC04 (Arquitetura de Computadores II) atingiram $F_{\text{critico}} = 1,0$ — o valor máximo possível — com caminho crítico absoluto de

²Histórico apresentado na Seção 3, semestre 2025.1.

Tabela 3: Resultado da recomendação para um aluno de CCO em 2025.1.

Rank	Disciplina	CH	Score	F_{critico}	Afinidade
1	Arquitetura de Computadores I	64h	6,9381	1,000	0,500
2	Cálculo A	64h	3,5682	0,500	0,650
Totais		128h / 144h	10,5063	Estratégia: exata	

Tabela 4: Resumo das execuções do protótipo para os quatro perfis de histórico testados.

Aluno	Curso	Disc. recom.	CH usada/capacidade	Score total	Conflitos em G_c	Estratégia MWIS
CCO-1	CCO	2	128h / 144h	10,5063	18	Exata
CCO-2	CCO	5	256h / 256h	7,3018	18	Gulosa
CCO-3	CCO	5	288h / 288h	24,0316	21	Gulosa
CCO-4	CCO	3	128h / 128h	4,9275	9	Exata
CCO-5	CCO	2	128h / 128h	17,8172	23	Gulosa
SIN-1	SIN	4	176h / 176h	5,5914	12	Gulosa
SIN-2	SIN	4	192h / 192h	6,4609	7	Exata

5 disciplinas, e consequentemente obtiveram os dois maiores scores da execução (11,7187 e 6,5183, respectivamente), bem acima da terceira colocada. O mesmo padrão se repete de forma ainda mais acentuada em CCO-5, no qual CTC001 e CRSC04 novamente atingiram $F_{\text{critico}} = 1,0$ com caminho crítico de 5, respondendo isoladamente por um score total de 17,8172 — o segundo maior entre os sete perfis, obtido com apenas duas disciplinas recomendadas. Esse resultado é coerente com o papel estrutural de CTC001 como disciplina fundamental do núcleo de Teoria da Computação, da qual derivam diversas disciplinas subsequentes do curso.

Já em CCO-4, a candidata mais bem pontuada (XDES02, Programação Orientada a Objetos) também atingiu $F_{\text{critico}} = 1,0$, mas com caminho crítico absoluto de apenas 3 — o normalizador $\text{Max_Caminho_Global}$ é local ao conjunto de candidatas disponíveis para aquele aluno, e não ao currículo inteiro. Comportamento análogo ocorre em SIN-2, no qual MAT00A (Cálculo A) lidera o ranking com caminho crítico de 5 e $F_{\text{critico}} = 1,0$, evidenciando que mesmo em um curso distinto (SIN), a disciplina de Matemática da Computação no início da grade segue exercendo papel de gargalo estrutural análogo ao observado em CCO. Isso é uma propriedade desejada do modelo: o sistema prioriza, dentre o que está *realmente disponível* para aquele discente naquele semestre, a disciplina de maior alcance futuro relativo — não a de maior alcance absoluto no currículo, métrica que seria irrelevante se a disciplina-gargalo do currículo completo não estivesse entre as candidatas elegíveis.

4.4 Densidade do grafo de conflitos e escolha de estratégia

O número de arestas em G_c variou de 7 (SIN-2) a 23 (CCO-5), refletindo perfis de oferta com diferentes graus de sobreposição de horário entre as candidatas elegíveis. Observa-se que a escolha entre estratégia exata e gulosa, controlada pelo limiar $|C| \leq 20$ (Seção 3.3), não se correlaciona diretamente com a densidade de G_c , mas sim com o número de candidatas: CCO-2, CCO-3, CCO-5 e SIN-1 — os quatro casos que acionaram a heurística gulosa — foram exatamente os perfis com maior

número de disciplinas candidatas totais, antes da filtragem por capacidade. Notavelmente, CCO-5 apresentou a maior densidade de conflitos entre todos os perfis (23 arestas) ainda que tenha resultado em apenas duas disciplinas recomendadas, ilustrando que um grafo de conflitos denso pode coexistir com uma capacidade de carga horária relativamente baixa.

Em todos os sete casos testados, G_c apresentou pelo menos 7 arestas, evidenciando que conflitos de horário são uma ocorrência comum entre as candidatas elegíveis de um mesmo semestre — o que reforça a relevância prática de incorporar a restrição de horário diretamente na formulação de otimização, em vez de tratá-la como uma etapa de filtragem posterior à seleção das disciplinas.

Não foi realizada, neste trabalho, uma comparação quantitativa de tempo de execução entre as duas estratégias do MWIS. Essa lacuna é discutida como limitação na Seção 5.

4.5 Qualidade da recomendação frente ao perfil do aluno

De forma agregada, os sete perfis testados evidenciam que o sistema responde de maneira sensível às particularidades de cada histórico, e não a um padrão genérico de recomendação. O score total das execuções variou em quase cinco vezes (de 4,93 em CCO-4 a 24,03 em CCO-3), refletindo diretamente o número de disciplinas obrigatórias com alto caminho crítico ainda disponíveis para cada aluno — CCO-3, com cinco recomendações de score elevado, encontra-se em um ponto da grade com maior concentração de disciplinas-gargalo desbloqueadas, enquanto CCO-4 já avançou por boa parte dessas dependências críticas, restando majoritariamente optativas de score base. CCO-5 representa um caso intermediário particularmente ilustrativo: apesar de recomendar apenas duas disciplinas, ambas concentram caminho crítico máximo, resultando no segundo maior score total da amostra — evidência de que a quantidade de disciplinas recomendadas não é, por si só, um indicador direto da qualidade pedagógica da recomendação.

Esse padrão é o comportamento esperado de um sistema cujo objetivo declarado (Seção 1.1) é priorizar o destranca-

mento da trajetória acadêmica: quanto mais disciplinas estruturais um aluno já completou, menor a urgência relativa das candidatas remanescentes, e o score consolidado captura essa transição de forma coerente em todos os perfis avaliados, tanto em CCO quanto em SIN.

5 Conclusões

Este trabalho apresentou um sistema de recomendação de matrícula fundamentado em Teoria dos Grafos, capaz de processar o histórico acadêmico real de um discente e recomendar, de forma automatizada, o conjunto de disciplinas que maximiza o benefício pedagógico de longo prazo, respeita a capacidade individual de carga horária e garante a ausência de conflitos de horário. A modelagem em dois níveis — o DAG curricular G_d , resolvido via Algoritmo de Kahn, e o grafo de conflitos G_c , resolvido via MWIS com restrição de mochila — mostrou-se adequada ao problema proposto, sendo validada com históricos reais de sete discentes dos cursos de CCO e SIN da UNIFEI.

Os resultados discutidos na Seção 4 confirmam que os mecanismos centrais do score pedagógico operam como projetado: o fator de caminho crítico identificou corretamente disciplinas-gargalo da grade, a afinidade por área diferenciou candidatas mesmo na ausência de descendentes desbloqueáveis, e a restrição de capacidade do MWIS foi sistematicamente saturada quando havia candidatas suficientes — evidenciando que o protótipo cumpre o objetivo geral proposto na Seção 1.1.

5.1 Limitações

Duas limitações relevantes foram identificadas ao longo do desenvolvimento e da validação:

- **Ausência de análise de desempenho computacional.** Não foram coletadas medições de tempo de execução para a estratégia exata por enumeração ($O(2^n)$) em comparação com a heurística gulosa ($O(n \log n)$), tampouco do tempo total do pipeline ponta a ponta. Embora o limiar de 20 candidatas tenha se mostrado suficiente nos sete casos testados — com a estratégia exata sendo acionada em três deles —, não há evidência empírica do comportamento do sistema no limite superior desse intervalo.
- **Validação restrita a sete perfis.** A amostra de históricos testados, embora suficiente para demonstrar o funcionamento do pipeline e ilustrar variações de comportamento do score em ambos os cursos atendidos (CCO e SIN), é pequena demais para sustentar conclusões estatísticas sobre a qualidade média das recomendações ou sobre a frequência de saturação total da capacidade observada em seis dos sete casos.

5.2 Trabalhos Futuros

A partir das limitações apontadas, sugerem-se as seguintes extensões para trabalhos futuros:

- Medir o tempo de execução da estratégia exata em função do número de candidatas, validando empiricamente o limiar de 20 disciplinas e avaliando a necessidade de técnicas de poda (*branch-and-bound*) para conjuntos maiores;

- Expandir a validação para uma amostra mais ampla de discentes, possibilitando análises estatísticas sobre a distribuição de scores e a taxa de saturação da capacidade de matrícula;
- Investigar fontes adicionais de afinidade além da média de notas por área, como o tempo de permanência do aluno em disciplinas da mesma área ou o desempenho relativo a colegas do mesmo período;
- Validar a usabilidade da recomendação junto a discentes reais dos cursos de CCO e SIN, avaliando se a ordem de prioridade sugerida pelo sistema corresponde à percepção do aluno sobre sua própria trajetória.

Em síntese, o sistema desenvolvido demonstra que a Teoria dos Grafos oferece um arcabouço formal adequado para representar tanto as dependências pedagógicas quanto as restrições operacionais do processo de matrícula, integrando-as em uma única formulação de otimização combinatória capaz de gerar recomendações imediatamente aplicáveis ao contexto real dos discentes da UNIFEI.

Referências

- Acuña-Cid, H. A., Ahumada-Tello, E., Ovalle-Osuna, Ó. O., Evans, R., Hernández-Ríos, J. E., & Zambrano-Soto, M. A. (2025). CRISP-NET: Integration of the CRISP-DM model with network analysis. *Machine Learning and Knowledge Extraction*, 7(3), 101.
- Al-Yahya, M. et al. (2023). Course recommendation system for university students using optimization algorithms. *International Journal of Advanced Computer Science and Applications*, 14(5).
- Kahn, A. B. (1962). Topological sorting of large networks. *Communications of the ACM*, 5(11), 558–562.
- Kanamori, K. et al. (2022). Curriculum recommendation system based on academic performance and prerequisite graph. Em *Proceedings of the IEEE International Conference on Systems, Man, and Cybernetics (SMC)*: IEEE.
- Novais, M. P. (2025). Geração e análise de grafos curriculares para planejamento acadêmico. Disponível em: <https://repositorio.ufsc.br/handle/123456789/270743>.
- Queiroz, R. M. C. (2023). Protótipo de sistema de recomendação para auxiliar na escolha de disciplinas optativas do curso de sistemas de informação da universidade federal do ceará campus quixadá. Disponível em: https://repositorio.ufc.br/bitstream/riufc/74740/1/2023_tcc_rmcqueiroz.pdf.

